AnjuGuard 两方向最小预实验报告

2026 年 11 月 1 日美东 运行证据保存于 2026 年 11 月 2 日 UTC 公开数据探索初测

本轮已实现并运行两个方向：方向一使用真实照片与 DINOv2 冻结特征；方向二使用真实视频帧与本机 Qwen HTTP 推理。原 App 未修改，新增付费 API 支出为 0。结果支持继续核验方向一的强基线可行性，但两个候选机制都没有显示可靠的额外研究收益。

方向一的强基线把留出 12 个同物对中的漏关联从 12 降至 3；C 去掉关系后结果不变。方向二 C 修复版减少请求，但 D 的上传量、等待和未知比例反而上升。独立人工复核尚未完成，真实风险效果、正式事件召回和质量非劣效均为未测。学术价值暂无法判断。

本报告主表固定呈现初次冻结运行。另一次完整独立复跑用于验证一键入口，其新测时延、开发选择和留出结果单列保留，不替换初次主表。

已执行范围

项目	方向一	方向二
真实数据	UW RGB-D Scenes v1 4 序列 64 图 315 框	ARKitScenes 6 视频 481.400 秒 483 帧
固定评价样本	48 对 各序列 6 同物 6 异物	250 个自动可见段 不是已确认事件真值
开发与留出	desk kitchen 各 16 图 meeting table 各 16 图	开发 136 帧 174 段 留出 347 帧 76 段
真实推理	DINOv2-small CPU float32	Qwen2.5-VL-3B MLX 4bit 固定提示词 本机 HTTP
分组局限	独立场地未验证 序列可能共享同一实物	沿官方 Training/Validation 3 个 visit 不等于 3 个家庭
独立人工复核	0 发布方框与身份待复核	0 事件开始与结束待复核

证据分层

实际测得：本机模型输出、HTTP 延迟、运行失败、请求与上传字节。离线回放：按原始视频 PTS 推进，按已测请求耗时释放结果。合成验证：同图冲突、局部变化、晚到响应、429、超时、重试等机制。未测：手机、互联网、功耗、云费用收益、人类确认的风险识别效果。

源码核查为 df281277215a1b55fd74dc8e43203e3954081976，工作区干净。实验置于 work/minipilot 的独立 codex/minipilot 分支；原源码和研究材料保持原位。没有授权云额度，也没有调用付费模型。

方向一 关联方法与留出结果

A 保留原来源条件、8 秒时间条件、IoU 阈值和贪心行为。公开照片没有 App source_id 或可靠拍摄时间，保持缺失，因此 A 无法跨帧关联。A_fix 只修同图、多对一等问题；它是初次结果后的补充工程审计，没有重调 B/C。另列来源序列适配辅助实验，不冒充原 App 行为。

B 使用固定 DINOv2 ROI 特征、余弦相似度、带不匹配节点的一对一分配。C 加框外 ORB 背景对应、通过一致性检查的近似平面几何和图像质量。关系缺失不补造；不输入实例 ID、人工关系或屏幕左右真值。B/C 在开发上共同设定 80% 自动判定目标，离散样本实际均为 20/24。

方法	误合并	漏合并	待确认	自动比例	已判错误率
A 原始	0	12	0	100.0%	50.0%
A 修复	0	12	0	100.0%	50.0%
来源适配 辅助	0	12	0	100.0%	50.0%
B 冻结特征	0	3	6	75.0%	16.7%
C 关系与质量	0	2	5	79.2%	10.5%
C 去关系	0	2	5	79.2%	10.5%
B 不拒判	0	3	0	100.0%	12.5%
C 取消待确认	0	3	0	100.0%	12.5%

分母为 24 对，其中 12 同物、12 同类别不同实例。全部方法运行失败 0、缺失 0、结果完整率 100%。待确认不算正确；本次没有误合并，不代表相似实物误合并问题已被解决。开发 desk 的六个异物对为不同类别易负例，开发/留出难度并不完全一致。

增益来自哪里

A → A_fix 在真实照片上没有收益，因为来源条件没有触发。B 不拒判时解决 9/12 个原规则漏关联，但这同时反映 A 的输入适用范围限制。C 与去关系消融逐对相同，B 不拒判与 C 取消待确认也逐对相同；当前不能认定 C 提升了身份匹配能力。

45 个图像对只有 1 对通过背景几何检查。C 已判错误率从 16.7% 到 10.5% 的变化伴随不同待确认集合，不是关系信息带来的证据。开发阈值生成的覆盖率曲线另存 CSV/PNG，不用测试曲线反选参数。

初次集成运行 7.468 秒；特征阶段 4.997 秒（含加载、裁剪、质量、预处理、推理与保存），其中编码器 forward 4.244 秒。共享几何准备 0.681 秒。末端判定耗时不能充当完整方法耗时，未独立测每种方法端到端速度。

方向二 固定模型与因果回放

固定 Qwen2.5-VL-3B 4bit 权重、processor、温度 0、512 token 上限、提示词及 JSON 结构。任务仅为家具出现与位置判断，类别为 chair、table、sofa、cabinet、bed、shelf。两档图片来自同一时刻，长边 720/1280，JPEG 质量 82。MOV 第一视频流按真实 PTS 抽取约 1 Hz 候选，并同步纠正图像和框的旋转。

A 每 6 秒固定 720；B 保留 H5 质量门控、dHash、冷却、退避与每视频 30 次上限。C_fix 修无效/不可用返回的去重与退避执行；C_tuned 仅开发选参，最后选回 C_fix 参数。D 加局部变化、答案过期检查和静默触发。服务单并发、超时 60 秒、指定可重试状态最多重试 1 次；视频结束仍在途的响应记未完成。

留出方法	请求	2 秒	5 秒	10 秒	20 秒
A 固定间隔	52	0/76	1/76	1/76	2/76
B 当前门控	52	0/76	2/76	2/76	3/76
C 修复	37	1/76	3/76	3/76	5/76
C 开发调参	37	1/76	3/76	3/76	5/76
D 候选机制	35	0/76	1/76	1/76	2/76

表中仅为派生可见性参考的及时匹配数，不是正式事件召回。模型类别与框须匹配，IoU⩾0.3，结果须在起始时刻加截止时间之前且仍可见时返回。没有已批准的质量门槛，不能宣称质量非劣效。留出 chair 和 sofa 的事件分母为 0，相关召回不可计算；关键风险类别未定义、未测。

工程收益与候选机制

B → C_fix 请求 52→37，减少 28.8%；20 秒代理匹配 3→5 段，但仍很低。首个分歧来自 quality_usable=false 后的退避：B 在视频 41069042 的 77.001 秒继续发送，C_fix 等待。本组没有 duplicate 门控触发，不能把收益归因于哈希修复。C_tuned 与 C_fix 相同，开发调参没有额外收益。

D 进一步降为 35 次请求，但 20 秒仅匹配 2/76，编码图片合计 4.14 MB，高于 C_fix 的 1.85 MB 和 A 的 2.52 MB；高分辨率请求使等待增加。D 的静默检查受质量、冷却和在途请求限制，不能作为回应时限保证。未运行密集高清参考；它即使运行也不能替代人工真值。

方向二 失败 延迟与成本

方法	无效输出	未完成	未知帧	过期帧	可用完成
A 固定间隔	10	0	164	10	27/52
B 当前门控	5	0	108	8	27/52
C 修复	4	0	141	22	23/37
C 开发调参	4	0	141	22	23/37
D 候选机制	6	2	298	4	16/35

“未知帧/过期帧”按 347 个候选时刻计。D 未知 298/347，答案覆盖仅 14.1%；不能用过期帧更少证明答案更新更好。过期统计只针对先前匹配物体已结束；旧空答案漏新物体由事件匹配与未知统计体现。最新无效结果记未知。运行无网络错误或超时重试，相关边界由合成测试验证；D 有 2 次视频结束未完成。

方法	请求结束 P50/P95 秒	可用返回条件 P50/P95 秒	调度 P95 毫秒	JPEG MB
A 固定间隔	1.32/2.15	1.32/1.93	11.55	2.52
B 当前门控	1.32/1.66	1.32/1.70	11.23	2.52
C 修复	1.32/1.67	1.33/1.71	9.80	1.85
C 开发调参	1.32/1.67	1.33/1.71	8.98	1.85
D 候选机制	3.31/3.82	3.31/3.76	11.33	4.14

请求结束延迟包括无效返回，不能解释为得到可用答案的等待。条件分位数只覆盖可用且在视频结束前完成的请求；所有方法完整请求集的可用答案 P50/P95 均不可计算。表中回放延迟采用原测 HTTP、原编码时长与当次调度开销，不采用缓存读取速度。

正式开发 64 次真实 HTTP 加 64 次记录重放；正式留出 139 次真实 HTTP 加 74 次记录重放。另对开发前 20 个候选做禁缓存短片技术重复，共 11 次真实 HTTP、22.75 秒墙钟，仅 A 有 1 次可用返回。样本太小，不能据此声称等待改善。模型加载约 1.66 秒与前期技术探针单列保留。

本地 API 支出始终为 0，云费用下降百分比不计算。各策略上传字节为其逻辑请求负载；实际新增传输与记录复用分开列在结果表。方向二强基线的质量水平尚不足以讨论“保质量降成本”。

可追溯失败与标注局限

方向一 meeting_small_1_p02、p05 在 B/C 都漏关联；table_1_p06 从 B 错误转为 C 待确认，去关系结果仍相同。方向二 A_fixed_41069042_000007_2 对应 PTS 6.014167 秒，真实输出框超出输入尺寸，被严格记为 invalid。HTML 可打开原图、上传图、原视频时间点和原始响应。

人工尚未复核。技术抽查确认图像直立，但 41069042 的 bed 投影框会混入前景柜，表明派生框存在遮挡污染。14/483 帧缺参考已单列；“未匹配代理框”不得称为人工确认误报，正式误报率仍未测。

复现 验证与后续证据

实验目录为 /Users/wangkai/Documents/ChatGPT/温肯科研/work/minipilot。依赖锁在 requirements.lock，模型/提示词/源码哈希在 configs 与 runs/provenance.json。初次结果、冻结配置、逐样本输出、失败和前期探针均保留。A_fix 补充审计、后处理参考完整率与曲线均有独立记录，没有用测试结果修改 B/C 或调度策略。

命令	行为
./run.sh setup	安装隔离环境和固定依赖
./run.sh smoke	合成与单元流程验证 不作真实研究结论
./run.sh recompute	从交付记录重新评价 无新模型请求
./run.sh real	下载公开数据和权重 在新目录运行真实实验
./run.sh provenance	记录代码 权重 环境与版本

已通过原规则等价、同图多实例、时间缺失、一对一冲突、真值置换不影响预测、同源划分、局部变化但哈希不变、晚到、质量拒绝、429、超时、重试、结束未完成及空分母/漏跑检查。正式调度日志审计无未来信息或重试违规，测试晚于开发冻结；逐项重算与原指标一致。日志中的模拟边界与真实失败分开保存。

独立复跑中，开发选择的 C 间隔变为 3 秒；留出调参版为 45 次请求、20 秒代理匹配 2/76，而 C_fix 仍为 37 次、5/76。重新测量会影响时刻和选参，这个重复结果提示调参不稳定。算法没有据此修改；完整对照保存在预实验明细的复现对照文件。

最小补充清单

先双人独立复核现有 48 对身份与 250 段事件。复核者分别使用空白副本，先看原图/视频，填类别、候选框、同异物、首次足够可判定、可见结束、状态变化及是否关键类别；不先看算法答案。分歧再由第三人或共同回看裁决。补充复核.xlsx 已预填入口，不填写虚构人名和签名。

补域数据最低为 3 个独立授权场地，每场地 2 布置×8 图，共 48 图；文件 S01_G01_P01.jpg，移动实物另建 G02。每场地 2 段 60–120 秒视频，共 6 段，文件 S01_V01.mov。覆盖线缆/箱子、同类相似物、远小目标、短暂出现、遮挡、重访及真实局部变化。S01 开发，S02/S03 留出；房间、相邻帧与裁剪不得跨组。

给导师的建议

建议先投入一轮小规模人工复核与困难配对，优先核验方向一的强基线和剩余失败；理由是任务可定义、已有真实身份标签和可运行基线，验证成本较低。暂不继续叠加关系复杂度。方向二先修固定模型的可用性、框定位和事件标注，再决定是否继续调度研究。这个优先顺序是资源安排建议，不是用户已选题、导师批准或学术创新结论。

来源：UW 数据与许可 https://rgbd-dataset.cs.washington.edu/dataset.html；ARKitScenes 数据说明 https://github.com/apple-aiml-research/ARKitScenes/blob/main/DATA.md；DINOv2 https://github.com/facebookresearch/dinov2；Qwen MLX 模型 https://huggingface.co/mlx-community/Qwen2.5-VL-3B-Instruct-4bit。固定 revision、完整提示词、原许可和引用在 ATTRIBUTION.txt 与 configs 中。