面向移动视觉任务的质量约束推理调度

方向二具体研究方案 以 AnjuGuard 为落地平台

研究问题与现有基础

本方向研究手机持续观察环境时，怎样在识别质量可接受的前提下，决定何时请求模型、上传哪张图、使用多高清晰度，以及是否升级到更强模型。应用对象包括家庭检查、办公室巡检、物品查找和移动视觉助手，不需要把研究结论限定在长者群体。AnjuGuard 是首个落地场景和实验平台。

建议作为工程与研究并重的候选主线。工程目标是形成可开关、可测量、可回退的推理调度模块，让 App 少等待、少传输、少花费；研究目标是检验一个质量受约束的调度机制是否优于强基线。节流、压缩和模型路由都已有研究，新增机制的创新性必须通过进一步查重和实验确认。

当前代码能复用什么

仓库版本 df281277 已有双档实时视频策略、清晰度与亮度门控、感知哈希去重、代表帧选择、模型并发控制和调用记录。原生策略设置了正常与降级两档分辨率、帧率及码率，并依据网络、温度和 AR 帧率切换；这些属于可复用实现，不等于已测得耗电或识别收益。[R1]

关键代码为 NativeRealtimeVideoPolicy.swift 的第 28—76、126—194 行，FrameQualityService.swift 的第 17—51 行，以及 assessment_service.py 的模型调用通道。vision.py 第 315—316 行会把真实请求耗时写入 latency_ms，已有 token 与模型版本记录可用于账单和实验追踪。仍需补齐队列等待、采集到结果的端到端耗时、策略决策和真机资源记录。[R1]

研究边界

第一版只改进可控制的 HTTP 图像分析路径。供应商 RTC 内部如何抽帧、使用多少视觉 token 或怎样执行模型，并未因接入 SDK 而变得可控，不能把编码降档直接解释成云推理成本下降。先冻结正式风险规则，不训练基础大模型，也不把系统节省费用解释为安全性提高。

已有工作与可检验差异

选帧、分辨率自适应与模型选择都不是空白领域。下列工作用于确定强对照和边界，不把在 AnjuGuard 中重新实现已有方法称为新贡献。

相关工作	已有能力	本项目需额外解决
Q-Frame ICCV 2025 [R2]	按查询选择视频帧并适配分辨率	真实在线时只能看已到达帧，且选择器耗时和费用也必须计入
AxiomVision ACM MM 2024 [R3]	视角感知的自适应视觉模型选择及边云协同	面向手机短时扫描，把小目标、证据过期和交互截止时间同时纳入
LiveVLM DAC 2026 [R4]	通过内部 KV 缓存与检索支持在线视频理解	黑盒 API 无法修改 KV；本项目只能在输入和请求层优化，需清楚区分能力

Q-Frame 的离线视频设定不能直接充当公平的在线对手：完整视频中的未来帧能提供当前系统看不到的信息。主实验应将可用信息限制为同一时刻以前的帧，并保持相同查询到达时间。若实现其前缀版本，应标为“在线适配版”，公开修改；原离线版本可作事后参考，不能混在在线成绩表中宣称胜负。[R2]

AxiomVision 可借鉴质量约束和代价建模，但其原实验任务与手机多模态助手不完全相同。若只复用策略思想，必须称为适配基线，保留其信息获取与探索开销。LiveVLM 依赖开放模型内部状态；有相应算力时可做独立系统比较，不能把它通过本地 GPU 的结果与按 API 计费的结果简单当作同一成本口径。[R3][R4]

候选贡献

候选贡献是：在可用历史有限、模型不可修改的条件下，依据经过校准的任务损失预测，联合安排时间、空间清晰度与模型级别，并给出质量和成本之间的实测关系。尤其检验“画面整体变化很小但关键细节发生变化”的失败情形。只有它超出当前规则及适配强基线，才保留独立论文主张。

方法与实现步骤

输入输出和控制范围

输入为当前及过去的图像、任务类别、最近已确认对象与时间戳、本地清晰度和图像特征、历史请求耗时、队列长度及可取得的网络状态。不得使用未来帧、测试标注、尚未返回的云结果或不可取得的模型内部置信度。输出是明确动作及理由：继续等待、上传低清整图、上传高清整图、上传带上下文的局部区域，或在基础请求之后升级模型。

第一轮先固定一个底层 VLM，仅优化发送时机与图像清晰度。第二轮再加入便宜与较强两档模型，避免无法分清收益来自策略还是换模型。局部裁剪必须保留位置与上下文关联，否则可能省了 token 却丢失“物品挡住通道”等关系。模型自报 confidence 不直接视为正确概率。

四步完成首个研究版本

- 步骤一：建立统一动作接口与日志。每次保存输入前缀摘要、策略版本、候选动作、所选动作、等待时间、传输量、真实 token、结果和失败状态；只记录必要元数据，影像按授权单独管理。
- 步骤二：在开发数据上离线执行有限动作网格，例如两档清晰度、整图或局部图、发送或等待。由人工标注计算每个动作的识别遗漏与位置误差，建立动作代价和任务损失样本，不以另一模型的回答直接替代真值。
- 步骤三：训练轻量损失预测器，如树模型或小型网络，预测不同动作的质量损失与延迟分布。在独立验证集校准误差界限；在线只用本地特征与已返回结果进行选择，无需训练基础 VLM。
- 步骤四：枚举可行动作，选取满足经验质量约束且预期总代价较低的动作；若无动作符合条件，选择较保守路径或明确返回暂不可判断。加入最大静默时长、证据过期检查和失败回退，防止系统一直不请求。

可先采用有限动作搜索，不急于使用强化学习。总代价包括传输、模型调用、选择器计算和用户等待。权重及质量阈值只能用开发、验证数据选择，正式测试前冻结；论文分别报告各成本分量，不能用一个任意加权总分掩盖质量下降。

质量约束是有限数据与指定分布上的经验约束，不能描述为任意家庭或任意模型上的绝对安全保证。持续漂移监测可作为工程功能，但在线自学习需要另设授权与评估，首版保持策略固定以便复现。

数据和评测场景

先导数据和正式数据

建议先导阶段采集 8—12 个授权空间、每处 2—3 段约 1—3 分钟的扫描，至少使用两种手机条件。内容覆盖粗粒度物体、细小物体与短暂可见线索，用于验证标注协议、动作网格、调用成本和效应方差。上述数量是启动建议，不是统计充分性的保证。

正式阶段可先按 45—60 个独立空间、每处 3—4 段轨迹估算工作量，并覆盖家庭、办公室或教室、走廊等至少两类场景。是否需要更多空间，应依据先导数据的聚类方差、预设非劣效界限和置信区间宽度计算，不能仅增加同一房间的视频帧来替代独立场景。规模不足时缩小结论适用范围。

标注包括对象或事件类别、可见起止时刻、位置区域、遮挡与光照，以及判断任务是否具备足够证据。主任务可设为给定对象的存在和位置判断、通行障碍识别，避免第一篇研究依赖医学风险评分。双人独立标注部分样本，报告一致性及分歧裁决；对短暂事件使用安全替代物，不制造真实用电或跌倒危险。

回放实验与真机实验分别回答什么

回放把同一采集序列按原时间顺序交给不同策略，并施加相同网络轨迹，可较公平比较信息选择与请求次数。缓存模型回答能降低开发费用，但必须按输入内容、模型版本和提示版本绑定缓存；缓存命中耗时不能充当真实在线延迟。策略依赖前一次结果时，回放也必须模拟结果到达时间。

真机实验检验端到端延迟、温升、掉帧和能耗。固定屏幕亮度、开始温度及应用状态，交错随机安排策略顺序，在相同任务上重复运行；实时 API 延迟另记录日期与服务状态。电池百分比只能作粗略辅助，报告毫瓦时或焦耳需要可靠能量测量工具；若没有，就不声称节能。

防止信息泄漏

训练、校准和测试按住宅或机构地点分组，来自同一建筑的近似房间、同一路径重复视频和衍生裁剪保持在同一组。至少保留一个设备或场景组合做外部分布测试。先导与开发素材不得回流正式测试；测试集一旦被用于调阈值，应改称验证集并另设新测试。

对照实验与判断标准

对照	用途	必须公平的部分
固定时间间隔和固定清晰度	最简单可解释基线	同一模型、输入时限和请求预算
现有质量加感知哈希策略	验证是否真正改善当前 App	保留原有逻辑，参数在验证集调优
Q-Frame 在线适配与模型选择适配	避免只赢弱基线	仅观察过去，计入额外计算和探索调用
密集高质量输入参考	估计丢失信息的空间	非真值、非质量上限；另计更高费用

主实验固定模型比较调度，再单独比较是否加入模型路由。消融分别移除细小目标特征、证据时效、校准损失预测和网络状态；每次只改一个模块。改变输入分辨率、采样时间和模型的全因子组合可先在开发集缩减，最终报告选定范围和选择依据。

指标必须有分母和单位

主要质量指标为任务事件召回率：标注的应报告事件中，系统在指定时间窗内正确报告的比例；同时报告精确率、未作判断比例及定位成功率。位置是否正确的 IoU 或距离阈值在实验前定义。超时、无效结构与服务失败都进入总任务分母，不能仅对成功返回的样本计算。

效率指标为每完成一次检查的美元或人民币成本、每次检查上传 MB、模型调用次数、端到端及请求服务 P50/P95 毫秒、选择器计算毫秒。条件允许再报告每次检查能量；费用按实际账单与模型价格版本核对，重试、失败请求、开发期探索和选择器调用单列。

质量非劣效与统计

可把召回下降不超过 2 个百分点作为讨论用的非劣效界限示例，但须由任务负责人和导师结合遗漏后果、先导方差及可接受误差确定，并在正式测试前登记。不能看到结果后放宽界限。高后果类别可设置更严格限制，并独立报告，不能由大量简单类别平均掉。

以空间为聚类单位，使用配对差值和聚类自助法计算区间。若新策略减基线的召回差值之单侧 95% 置信下界高于负的预设界限，才支持该数据条件下的非劣效；同时检查精确率和未作判断比例没有不合理恶化。若区间跨越界限，结论是不确定，不能写成无显著差异所以同样好。

只有通过预先设定的质量条件后，才检验成本或延迟改善，并报告置信区间和不同场景的收益分布。多项探索性比较需标明探索性质并控制多重比较。弱网、429、超时、画面变化后答案过期等失败分别报告；不应只展示漂亮的平均值。

开发计划与资源预算

十六周执行安排

- 第 1—2 周：核对相关工作，冻结主任务和 HTTP 控制范围，完成统一日志、固定间隔及现有策略基线；输出协议和可复现一次运行。
- 第 3—4 周：完成先导采集、标注和动作代价网格，确认 API 能控制的分辨率与计费行为；决定非劣效界限、正式样本量和预算。
- 第 5—8 周：实现轻量损失预测、有限动作选择和失败回退，在验证集调参；输出带功能开关的 App 模块及离线回放工具。
- 第 9—12 周：冻结策略，进行分组留出测试、强基线与消融；补充真机、网络波动和外部分布测量，不根据测试结果反复调阈值。
- 第 13—16 周：分析失败、复核账单与统计，形成数据说明、可复现实验包、论文初稿和 App 集成验收；若需要新增数据，延长计划而不赶结论。

建议三名学生分别负责移动端与网络、策略与后端、数据与实验，每人每周约 8—10 小时；十六周约 384—480 学生工时，导师指导另计。这是工作量估算，未计入长时间审批和无法取得场地的延误。普通开发电脑与两部不同条件的手机可启动，第三部手机用于泛化测试；没有对应设备时先不主张跨设备结论。

预算用可调整参数计算

先测 100—200 次真实请求获得平均每次费用 c。模型费用预算为 N×c×(1+r)，其中 N 包括所有基线、重复和策略开发请求，r 为重试及波动储备。示例：若 N=12000、c=0.02 美元、r=0.30，则为 312 美元；这些数仅用于演示估算，不是当前供应商报价或实际采购承诺。正式申报按所选模型的实测价格、币种和学校报销规则更新。

另列手机借用或购置、可选网络与能量测量工具、存储、场地及标注工时。通常不必购买训练基础模型所需的大型 GPU；若为复现开放模型基线租 GPU，要单独核算并说明与 API 路线的成本口径。

继续与停止标准

四周后若 API 不提供所需控制、数据无法授权、强基线已消除主要收益，或选择器开销超过节省，应缩减动作集或停止独立论文路线。若质量约束反复失败，也不能用更宽阈值挽救结果。保留已验证的限流、观测和回退作为工程成果；只有在独立验证中呈现稳定质量与效率优势，才进入正式评测。

成果形式与项目申报

工程成果怎样验收

交付内容包括可切换的 HTTP 推理调度模块、策略配置与版本记录、逐请求费用和时延追踪、可复现回放工具、失败回退及集成文档。验收时应能重放同一输入比较旧策略与新策略，解释每次发送或等待的原因，并在策略关闭时恢复现有路径。不能把研究模式默认开启到真实用户而跳过稳定性验证。

学术成果和会议匹配

论文主张应围绕可泛化的质量约束调度问题及其方法、跨场景实验和失败边界，App 是落地证据。如果最后只有固定阈值改良和调用数下降，作为工程报告有价值，但不足以据此判断达到 CCF A/B 研究长文水平。若策略在严格质量约束下改善真实移动系统运行，可优先评估 PerCom；若有充分实地部署及普适感知贡献，再考虑 UbiComp/IMWUT；多模态方法贡献足够清楚时可评估 ACM MM。[R5][R6]

截至 2026 年 10 月 29 日核对的 CCF 目录中，PerCom 为 B，UbiComp/IMWUT 和 ACM MM 为 A。类别不能替代选题契合与证据要求；IMWUT 具有期刊发表与会议展示机制。项目计划不承诺录用，不预填尚未核实的下一轮截止日期；最终按当年征稿与学校成果规则确认。[R5][R6][R7]

对应自然科学申请书

立项依据写移动视觉助手的质量、时延和费用冲突，并结合 Q-Frame 等已有工作说明尚待验证的差异。研究内容分为任务损失与代价建模、在线决策、可复现实验三项；关键科学问题是有限历史和黑盒模型条件下如何控制经验质量损失。研究方法写清开发、校准与留出测试，不把结果目标写成已取得成绩。

研究基础可据实列出 AnjuGuard 已有采集、质量门控、并发与日志代码；工作条件写实际可借设备、API 预算、授权场地和指导力量。年度计划以十六周先完成可行性与一轮验证，随后根据结果补充研究。预期成果可设为一个可运行模块、一套授权且去标识的评测材料、一份完整实验报告和一篇可投稿论文稿。

申请题目建议使用“面向移动视觉任务的质量约束推理调度方法研究”。候选创新写为待验证的研究设计，避免使用首次、保证准确、显著降低等未经实验支持的措辞。已有开源代码和借鉴方法须清楚归属，最终论文必须报告失败情形及成本测量范围。

参考资料与来源

核查日期为 2026 年 10 月 29 日。文中编号对应下列来源。研究方案中的样本量、阈值、里程碑和创新点均为拟议设计，尚不是实验结果。

[R1] AnjuGuard 公开代码与实现状态 固定提交 df281277

只读核验代码；NativeRealtimeVideoPolicy.swift、FrameQualityService.swift、assessment_service.py、providers/vision.py。代码实现不等于真机实验结果。

[R2] Q-Frame Query-aware Frame Selection and Multi-Resolution Adaptation for Video-LLMs ICCV 2025

核验作者论文 v3；任务相关选帧和分辨率适配的直接先例。

[R3] AxiomVision Accuracy-Guaranteed Adaptive Visual Model Selection for Perspective-Aware Video Analytics ACM MM 2024

核验作者论文；视角感知模型选择与边云协同的直接先例，原有保证不能直接迁移为本项目保证。

[R4] LiveVLM Efficient Online Video Understanding via Streaming-Oriented KV Cache and Retrieval DAC 2026

核验 2026 年 4 月 23 日版本，页面注明 DAC 2026；在线内部缓存方法，与黑盒 API 调度控制范围不同。

[R5] CCF 人机交互与普适计算推荐目录

核验 PerCom B 与 UbiComp/IMWUT A；不构成录用或学校认定承诺。

[R6] CCF 计算机图形学与多媒体推荐目录

核验 ACM MM A。

[R7] CCF 第七版国际学术会议和期刊目录正式说明

2026 年 3 月 31 日发布、4 月 9 日勘误；会议认定范围为 Full 或 Regular 研究论文，具体校内认定另行确认。