Research Proposal for

Student Partnering with Faculty/Staff Research Programs

（Natural Science）

Title of the proposed research project

面向移动室内巡检的质量约束视觉推理调度研究

Quality Constrained Visual Inference Scheduling for Mobile Indoor Inspection

Part I

1. Project context (including research significance, research overview and prospect in China and abroad, and importance of the proposed study. A list of references should be provided).

项目的立项依据（研究意义、国内外研究现状及发展动态分析，需结合科学研究发展趋势来论述科学意义。附主要参考文献目录）

研究意义

本项目拟研究手机连续观察室内环境时，怎样在不明显增加关键遗漏的前提下，减少不必要的图片上传和模型请求。例如，相机停留在同一面墙前时，可以少发送重复图片；画面中刚出现一根细线缆时，则应及时保留足够清晰的证据。研究以 AnjuGuard 为验证平台，面向家庭、办公室和教学空间，不限定使用者年龄。

手机巡检的费用和等待时间不仅取决于模型大小，也取决于何时发送、发送哪张图以及图像是否足够清楚。单纯降低清晰度或延长发送间隔可能节省资源，却漏掉细小目标和短暂出现的线索。本项目希望建立一种可解释的调度方法：先判断任务质量能否达到约定要求，再选择代价较低的请求方式，使 App 的改进有可复核的依据。

国内外研究现状及发展趋势

RASSAR 已使用移动增强现实、计算机视觉和 LiDAR 支持室内无障碍与安全检查，提供了移动巡检的应用基础[1]。AnjuGuard 基于其二次开发，本项目将复用现有采集和评估链路，研究请求层的调度机制；上游扫描能力与已有工程功能不作为新的学术贡献[5]。

视频理解研究已开始联合优化帧选择与图像清晰度。Q-Frame 根据问题内容选择视频帧，并分配不同分辨率，说明统一抽帧并非唯一方式[2]。AxiomVision 研究视角变化下的视觉模型选择与边云协同，说明依据任务质量选择不同代价的模型已有先例[3]。因此，选帧、压缩或切换模型本身均不足以构成本项目的创新。

在线理解也出现了针对模型内部状态的优化。LiveVLM 通过面向流式视频的 KV 缓存组织和检索减少冗余[4]。本项目首阶段面对的是无法修改内部状态的模型接口，重点在图片输入、请求时机和失败处理。开放模型内部优化与接口外部调度具有不同条件，不能直接套用其效果或费用口径。

研究切入点

拟重点检验“整体画面变化很小，但关键证据已经变化”的情形：能否结合图像质量、局部变化、历史结果时效和请求等待情况，判断何时可以省一次请求，何时必须升级清晰度或重新判断。调度只能使用当前及过去已获得的信息，不能偷看后续视频。质量约束是指定任务和数据条件下的经验要求，不是对任意场景的安全保证。

主要参考文献

[1] Su X, Zhang H, Cheng K, et al. RASSAR: Room Accessibility and Safety Scanning in Augmented Reality. CHI, 2024. DOI: 10.1145/3613904.3642140. https://arxiv.org/abs/2404.07479

[2] Zhang S, Yang J, Yin J, Luo Z, Luan J. Q-Frame: Query-aware Frame Selection and Multi-Resolution Adaptation for Video-LLMs. ICCV, 2025. https://arxiv.org/abs/2506.22139

[3] Dai X, Zhang Z, Yang P, Xu Y, Liu X, Lui J C S. AxiomVision: Accuracy-Guaranteed Adaptive Visual Model Selection for Perspective-Aware Video Analytics. ACM Multimedia, 2024. https://arxiv.org/abs/2407.20124

[4] Ning Z, Liu G, Jin Q, et al. LiveVLM: Efficient Online Video Understanding via Streaming-Oriented KV Cache and Retrieval. DAC, 2026. DOI: 10.1145/3770743.3804012. https://arxiv.org/abs/2505.15269v2

[5] AnjuGuard 开源项目. 原生视频策略、图像质量服务及后端视觉请求实现，代码提交 df281277215a1b55fd74dc8e43203e3954081976. https://github.com/banshanbans/AnjuGuard

2. Project description, objectives, and the key scientific problems to be solved (this section should be detailed and explicit).

项目的研究内容、研究目标，以及拟解决的关键科学问题（此部分为重点阐述内容）

研究内容

第一，建立面向巡检任务的质量与代价记录。将每次模型请求与实际可见事件对应，记录输入图像、发送时机、结果到达时间、上传量、模型用量及失败状态，明确哪些节省来自删减重复输入，哪些节省以遗漏信息为代价。

第二，研究质量约束下的有限动作选择。第一版固定模型，只选择等待、低清整图或高清整图；先判断动作能否满足任务要求，再比较其费用与等待时间。核心方法成立后，再单独研究局部裁剪与两档模型升级，避免把换模型带来的收益误认为调度方法的贡献。

第三，建立离线回放与真机实验相结合的评测流程。相同视频按原时间顺序交给各策略，检验信息选择；真机实验另外检验实际延迟、温升和可靠性。有效策略以可开关模块接入 App，出现错误时能够回退并保留原因。

研究目标

核心目标是在预先确定的事件召回、误报及未判定限制下，降低每次扫描的实际模型费用或端到端等待时间。拟检验的假设是：结合局部证据变化和历史结果时效，比仅看整体相似度或固定发送间隔更能保留关键线索，并减少重复请求。优势必须在未参与调参的场地上体现，不预填未经测量的提升比例。

质量指标分别覆盖细小目标、短暂可见事件和通道障碍，不能用大量容易画面的平均正确率掩盖关键类别的遗漏。召回容许下降幅度、误报上限、未判定上限和回应时限，由导师依据任务后果及先导数据确定，并在正式测试前固定。若无法确认这些要求，先完成可行性分析，不作质量达标结论。

拟解决的关键科学问题

一是信息价值判断：在尚未调用模型时，哪些低成本线索能预测继续等待或降低清晰度造成的任务损失？二是证据时效：当场景发生局部变化时，如何识别先前答案已不适用，避免用过期结果掩盖新事件？三是质量与代价权衡：在网络不稳定、调用失败和模型不确定时，如何保留可解释的保守处理，并量化为此付出的费用和等待时间？

3. Research approach and methodology, as well as feasibility analysis (including the description of the research methodology, technical route / roadmap, experimental methods, key technologies, etc).

拟采取的研究方案及可行性分析（包括研究方法、技术路线、实验手段、关键技术等说明）

技术路线

首阶段仅研究可以控制输入与调用的 HTTP 图片分析路径，不推断供应商实时视频服务内部的抽帧和计费行为。先固定任务规则、模型版本和提示，建立统一日志，再实现有限动作策略。模型自身报出的 confidence 不直接视为正确概率；人工标注只用于训练和评价，不能成为运行时输入。

策略输入包括当前及过去图像的清晰度、亮度、局部变化、近期已返回结果、结果距今时长、请求队列和可取得的网络信息。使用冻结视觉特征或轻量计算提取候选线索，其额外耗时与费用计入总成本。输入中不包含未来帧、尚未返回的结果或不可获取的模型内部状态。

在开发数据上执行有限动作网格，比较不同发送时机与两档清晰度造成的事件遗漏、位置错误、费用和等待时间。先以可解释规则形成强基线；数据足够时，再拟合轻量任务损失预测器，在独立验证组上校准其误差。在线枚举可行动作，优先选择满足经验质量条件且代价较低的动作。无法可靠估计质量时，不强行选择低成本路径。

设置最大静默时长、结果过期检查与截止时间。已出现新局部变化、证据不足或低清结果不可靠时，优先补发当前高清整图；后续模型路由实验中，低成本模型不确定时可升级强模型。网络断开、限流或超时采用有上限的重试与退避，

达到截止时间仍失败则明确标记未完成，保留人工复核入口，不返回“未发现问题”。所有回退、重试和未判定均进入评测。

数据采集与标注

前两周先在 3–5 个获授权空间，每处录制约 2 段 1–2 分钟手机扫描，覆盖重复画面、细小物体、遮挡、短暂出现及局部变化。该规模用于验证问题和记录方法，不能支持泛化结论。条件具备后，扩展至 8–12 个先导空间，估计标注耗时、场地间差异和模型费用；正式规模根据独立场地数量、质量界限与区间精度确定。

每个事件标注类别、区域、首次具备足够可见证据的时刻、可见结束时刻和状态变化。以首次可判定时刻起算回应时限；错误沿用旧状态另计过期答案。至少 20% 的分层样本由两人独立标注并裁决分歧，关键短暂事件优先双人复核。使用安全替代物并落实场地许可，避开人脸和私人信息；公开影像另需发布授权。

训练、校准与测试按家庭或机构场地划分，同一场地的房间、轨迹、邻近时段重复扫描及衍生裁剪保持在同一组；另做跨采集时段检验，避免同一布置泄漏。正式测试前冻结划分、模型和策略。场地不足以保留独立测试组时，仅报告小试发现；条件允许再留出不同手机或场景组合检验适用范围。

公平对照与消融

比较固定间隔固定清晰度、现有质量与感知哈希策略、调优后的简单规则，以及 Q-Frame 的在线前缀适配方案[2]。引入模型路由时，再增加 AxiomVision 思路的适配对照[3]。适配修改与复现范围明确记录，不能把完整视频离线选帧直接当作在线对手；所有方法在同一时刻只看到相同前缀，选择器和探索请求开销也计入。现有策略保留原样与修复明显工程限制后的两个版本，避免只与存在已知缺陷的实现比较；这类修复本身不作为算法创新。

设置密集高清输入作为高成本参考，它不是人工真值或质量上限。主实验先固定同一模型比较调度，再单独增加模型级别，分别移除局部变化、结果时效和损失校准机制。所有参数只用训练与验证数据选择。LiveVLM 需要访问模型内部状态，可在算力允许时作为另一系统条件的补充研究，不与接口费用结果直接合并[4]。

离线回放保留原视频时间和统一网络轨迹，并模拟请求结果的实际到达时间，防止策略提前使用云端回答。缓存可以节省开发调用，但按图像、模型和提示版本绑定；缓存访问速度不能充当真实推理时延。真实在线测试则在相同任务条件下交错安排策略顺序并重复测量，记录日期、设备温度、网络和服务状态。

质量与效率评价

主要质量指标是时限内事件召回率，即具备可见证据的真值事件中，被及时正确报告的比例。匹配同时要求事件类别正确与位置达到预定标准，阈值在验证后冻结。另报告精确率、每分钟误报、定位成功率、过期答案和未判定比例。超时、请求失败及拒绝判断不从总事件分母删除；关键类别分别报告，整体召回达标不能替代逐类检查。

主要效率指标为每次扫描实际调用费用及采集到可用结果的 P50/P95 延迟，另列上传 MB、调用次数、排队时间和选择器计算时间。重试、失败计费和模型升级一并计入，开发探索费用单列。超时样本另报比例；若超过一半或相应尾部分位样本未完成，不把仅成功请求的分位数写成全体响应时延。

以场地为聚类单位计算同一输入下的配对差值及置信区间。若新策略相对基线的召回差值，其单侧 95% 置信下界高于预定负界限，且关键类别、误报与未判定要求均满足，才支持该条件下的质量非劣效。样本过少或区间跨过界限应报告不确定。通过质量门槛后，再检验预先选定的费用或延迟终点，不能在测试后放宽门槛换取成功结论。

真机测试固定亮度、起始温度及后台状态，测量温升、掉帧和运行稳定性。只有具备可靠能量测量工具并说明测量范围时，才报告焦耳或毫瓦时及节能结论；电池百分比不作为准确能耗证据。合成弱网和离线回放分别注明，不能代替真实网络与真机结果。

可行性与调整策略

首版采用有限动作、冻结模型和轻量规则，降低训练资源需求。先以少量真实请求验证接口控制与费用，再确定规模。若质量预测不可靠，缩小动作集并采用保守规则；若强基线已解决主要问题，保留工程收益并调整研究主张。没有真实数据、关键对照或费用证据时，不宣称方法有效或更省资源。

4. Originality and innovative aspects of the proposed study.

本项目的特色与创新之处

本项目拟验证以下研究设计的增量价值。已有工作已覆盖自适应选帧、模型选择及流式计算；本项目的创新性取决于独立评测，不能仅以组合这些技术作出原创结论。

面向关键事件的质量约束

把细小目标与短暂事件的及时发现作为质量要求，将未判定、超时和关键类别遗漏同时纳入评测。重点检验这种任务约束是否比整体画面质量或平均正确率更能指导请求决策，并说明它何时失效。

局部变化与证据时效共同参与调度

在模型内部不可修改、只能看到历史输入的条件下，联合判断新证据价值和旧答案有效期，选择发送时机与清晰度。通过消融验证它能否在相同质量约束下优于调优规则及公开适配基线，并扣除选择器自身开销。

可复核的质量与代价关系

用同一事件标注串联时间回放、真实请求和真机测试，区分信息选择收益、云服务波动及设备代价。交付逐请求证据和失败归因，使研究收益能对应到 App 的等待时间、账单与可靠性；单纯增加日志或功能开关只算工程成果。

5. Annual research plan and expected results (including important academic exchange activities to be organized, international cooperation and exchange programs, etc.).

年度研究计划及预期研究结果（包括拟组织的重要学术交流活动、国际合作与交流计划等）

项目按获批启动后的 12 个月安排，前两周进行小试，前约 16 周争取形成首轮可复现实验。实施节奏随导师意见、授权场地和实际投入调整。

第 1 个月 明确任务与最低成本验证

第一周核对接口能力、事件定义和日志，建立固定间隔及现有规则对照；第二周在 3–5 个授权空间完成小试并核对人工标注。月底形成问题是否存在、真实请求费用和继续条件的短报告，确认导师、资源及必要采集审批。

第 2–3 个月 先导数据和基线

完成 8–12 个空间的先导采集与质量复核，建立有限动作数据和时间回放，复现关键适配基线。根据先导差异确定正式数据规模、预算、主要终点和质量门槛，冻结数据分组规则。

第 4–6 个月 方法实现和正式采集

实现局部变化、证据时效和轻量损失预测，先固定模型完成时机与清晰度调度，再按结果决定是否加入模型升级。只在开发及验证数据上调参，完成正式数据采集与复核，检查收益是否超过简单规则。

第 7–9 个月 独立评测与真机验证

在冻结测试组上完成质量约束检验、效率对比、消融和失败分析，补充真实网络与设备测试。报告场地差异、关键类别和超时表现；资源不足时缩小适用范围，不靠反复调整测试阈值获得结果。

第 10–12 个月 App 集成与成果整理

将有效策略以开关方式接入原型，验收请求追踪、回退和关闭策略后的恢复行为。整理代码、标注规范、实验报告和论文初稿，依据实际贡献及导师意见准备适合的 CCF A/B 类会议投稿，不将录用列为保证成果。

预期成果与学术交流

预期形成一个可复现的调度原型、一套事件级评测协议、质量与费用对照报告及一篇论文稿。开展阶段组会、一次基线复现分享和一次校内成果交流；条件允许时参加相关会议或线上讨论。数据开放以授权为前提，目前没有已落实的国际合作或出访安排。第 1 月和第 3 月分别复核问题价值、接口控制与数据可得性，达不到继续条件时及时缩小或调整路线。

Part II

1. Basis and prior research (prior research work related to the proposed project and related outcomes achieved in the past).

研究基础（与本项目相关的研究工作积累和已取得的研究工作成绩）

已有工程基础

现有 AnjuGuard 代码提供图片质量评估、代表帧选择及模型请求入口[5]。原生视频策略包含正常与降级两档参数，并根据网络、温度和 AR 帧率切换；图像质量服务计算亮度与清晰度，代表帧选择采用排序和感知哈希过滤。这些模块可作为研究入口和现有策略基线，不代表已完成质量约束调度。

后端视觉请求可记录模型名称、输入输出 token 和请求耗时，为统一实验日志提供基础。研究仍需补足采集到结果的端到端时间、队列等待、事件匹配、动作理由与真实账单核对；实时视频编码降档也不能直接推导为云模型调用费用下降。

已有积累与结果界限

已具备方向二研究方案、路线比较和相关代码检查材料。先前 Mock 与合成测试只涉及部分程序行为，尚没有可作为本项目成果的真实质量提升、真机能耗或跨场地实验结论。后续将区分 RASSAR 上游能力、既有工程实现和本研究新增方法，并保留版本及许可记录[1,5]。

2. Working conditions (including existing conditions for experiments, missing conditions and proposed ways to solve those problems).

工作条件（包括已具备的实验条件，尚缺少的实验条件和拟解决的途径）

已有条件

目前可确认的条件为本地工程源码、研究设计和公开论文资料。普通手机 RGB 视频即可用于最小回放实验，首版不依赖 LiDAR 或训练基础大模型；关键模型服务和实际手机条件仍需落实。

尚缺条件与解决途径

指导教师、学生分工及每周投入尚待确定。拟围绕移动端与日志、调度与后端、数据与实验三类任务安排工作，依据实际人力缩减首版范围。授权空间与标注人员需在采集前落实，数据许可和必要审批由导师指导确认。

手机型号、模型调用额度、GPU 和能量测量工具尚未确认。先借用普通手机与少量真实调用验证控制范围；跨设备结论须补充不同设备，可靠节能结论须补充对应测量工具。模型预算依据先导请求的实际费用，乘以各基线、重复实验及开发请求总量，再留出明确重试储备；不将示例价格或未经批准的采购写成已有经费。

缺少开放模型算力时优先完成接口外部调度；场地不足时仅报告可行性；无法复现强基线时明确比较范围。年度起止日期、申报类别、费用额度及提交要求按学校当轮通知与导师意见确认。